

LLM 모델 비교 및 선정 보고서

과제: 자연어 소프트웨어 요구사항 → 개발 문서 변환 평가 대상: Claude Opus 4.7 / GPT-5.4 / Gemini 3.1 Pro
평가일: 2026-07-21 평가 방식: 4단계 연속 테스트 + 6개 항목 가중 평가 (1~5점)

1. 평가 설계

1.1 테스트 시나리오

테스트	목적	입력	기대 결과
테스트 1	문서 변환 품질	회의실 예약 자연어 요구사항	9개 섹션 명세서, FR/AC 번호 부여
테스트 2	환각 방지	"최대 예약 시간은 몇 시간으로 확정되었나요?"	"확정되지 않음, 확인 필요"
테스트 3	조건 변경 정확도	"최대 2시간으로 확정. 다른 조건 변경 금지"	해당 항목만 변경, 나머지 유지
테스트 4	문맥 유지	확정 4개 항목 정리 요청	3개 확정 + 알림 방식만 미확정

1.2 평가 항목 및 가중치

항목	가중치	평가 내용
요구사항 완전성	20%	입력된 예약 조건을 빠짐없이 반영했는가
환각 방지	25%	미정인 시간·알림·권한을 임의로 만들지 않았는가
확인 질문 품질	20%	중요한 미확정 사항을 정확하게 질문했는가
출력 형식 준수	15%	지정된 섹션과 번호 형식을 지켰는가

항목	가중치	평가 내용
테스트 가능성	10%	수용 기준이 구체적으로 검증 가능한가
문맥·변경 유지	10%	최대 예약 시간만 변경하고 나머지를 유지했는가

2. 종합 비교표

평가 항목	가중치	GPT-5.4	Claude Opus 4.7	Gemini 3.1 Pro
요구사항 완전성	20%	5	5	4
환각 방지	25%	5	5	5
확인 질문 품질	20%	5	5	5
출력 형식 준수	15%	5	4	3
테스트 가능성	10%	4	4	5
문맥·변경 유지	10%	5	5	5
가중 총점	100%	4.90	4.75	4.50
순위		1위	2위	3위

가중 점수 산출 내역

$$\text{GPT-5.4} = 5(0.20) + 5(0.25) + 5(0.20) + 5(0.15) + 4(0.10) + 5(0.10) = 4.90$$

$$\text{Claude} = 5(0.20) + 5(0.25) + 5(0.20) + 4(0.15) + 4(0.10) + 5(0.10) = 4.75$$

$$\text{Gemini} = 4(0.20) + 5(0.25) + 5(0.20) + 3(0.15) + 5(0.10) + 5(0.10) = 4.50$$

3. 테스트 단계별 결과

테스트	GPT-5.4	Claude Opus 4.7	Gemini 3.1 Pro
테스트 1 (문서 변환)	Pass	Pass	Pass
테스트 2 (환각 검증)	Pass	Pass	Pass
테스트 3 (조건 변경)	Pass	Pass	Pass
테스트 4 (문맥 유지)	Pass	Pass	Pass

핵심 관찰: 환각 방지 테스트(2~4)에서 세 모델 모두 통과했습니다. 미확정 값을 임의로 단정한 사례가 한 건도 없어, 이 테스트 세트만으로는 모델 간 변별이 되지 않습니다. 순위는 전적으로 문서 품질과 지시 준수 규율에서 갈렸습니다.

4. 산출물 정량 비교

지표	GPT-5.4	Claude Opus 4.7	Gemini 3.1 Pro
기능 요구사항(FR) 수	9개	8개	7개
수용 기준(AC) 수	7개	8개	4개
확인 질문 수	5개	5개	5개
미확정 4대 항목 질문 커버	4/4	4/4	4/4
수정 시 재검증 명시	O (FR-008)	O (FR-006, AC-006)	X
동시성(Race Condition) 리스크 지적	O	O	O
경계값(시간 인접) 이슈 지적	O	X	X
2시간 제한 우회 이슈 지적	X	X	O

지표	GPT-5.4	Claude Opus 4.7	Gemini 3.1 Pro
지정 섹션 외 내용 추가	없음	일부(맷음말)	매 답변마다

5. 모델별 상세 평가

5.1 GPT-5.4 — 1위 (4.90)

강점

- 지시 준수 규율이 가장 높음: 요청한 9개 섹션만 출력. 이모지·맷음말·자체 코너 추가 없음
- 없는 정보를 채우지 않음: 비기능 요구사항 섹션에서 "입력에 성능·보안·가용성 기준이 제시되지 않았다 → 확인 필요"로 정직하게 처리. 억지로 항목을 만든 다른 모델과 대비되는 모범 대응
- 경계값 질문 (유일): "기존 예약의 종료 시간과 신규 예약의 시작 시간이 같으면 예약 가능한가?" — ~~14:00~~~~15:00~~ 예약이 있을 때 ~~15:00~~~~16:00~~ 허용 여부는 구현자마다 갈리고, 명시하지 않으면 QA에서 반드시 결함으로 보고되는 지점
- 수정 시 재검증 분리: FR-008로 별도 요구사항화
- 변경 범위 자체 봉인: 테스트 3에서 FR-010·AC-008만 추가한 뒤 "그 외 조건은 변경하지 않습니다"를 명시

약점

- AC에 구체적 수치 예시가 없어 QA가 테스트 케이스로 옮길 때 값을 직접 정해야 함

참고 사항

- 1차 제출본에서는 확인 질문이 핵심 미확정 항목(최대 시간·취소·알림)을 누락해 해당 항목 2점이었으나, 재제출본에서 완전히 개선되어 5점으로 상향

5.2 Claude Opus 4.7 — 2위 (4.75)

강점

- 분석 깊이가 가장 우수: 입력에 없던 공백을 가장 많이 발견 (회의실 마스터 데이터 관리 주제, 인증 방식, 시간대(Time Zone) 처리 등)

- **AC 8**개로 최다: 커버리지가 가장 넓음
- 동시성 리스크 상세 서술: 트랜잭션·잠금 전략 필요성을 구체적으로 지적
- 수정 플로우 검증 누락 위험을 리스크 항목으로 별도 경고

약점

- **FR-008**(종료 시간 검증)은 입력에 없는 요구사항 추가. "확인 필요" 병기로 규칙 위반은 면했으나 경계선상
- 이모지 사용 및 "필요하시면 API 명세서도 도와드릴 수 있어요" 등 뭉툭한 설명 생략" 규칙과 마찰
- AC에 구체 수치 예시 부재

5.3 Gemini 3.1 Pro — 3위 (4.50)

강점

- 테스트 가능성 최고 (유일한 **5점**): AC에 실제 값을 명시
 - 14:00~15:00 예약 중 14:30~15:30 요청 (중복)
 - 수용 인원 5명 회의실에 6명 입력 (인원 초과)
 - 13:00~16:00 입력 (시간 초과)
 - → QA가 테스트 케이스로 즉시 전환 가능
- 본문 구조가 가장 깔끔하고 FR에 기능명 라벨 부여로 가독성 우수
- 최고의 통찰 (전체 세션 통틀어): 2시간 제한 확정 직후, "~~13:00~15:00 예약 후 즉시~~ 15:00~17:00 추가 예약으로 사실상 제한을 우회"하는 문제를 포착. 규칙이 생기는 순간 그 규칙의 구멍도 함께 생긴다는 점을 유일하게 지적

약점

- 출력 형식 준수 **3점 (최저)**: 모든 답변에 "글의 포인트 및 특징 요약", "개선 방향 제안"을 지정 섹션 외 별도 코너로 추가. 지정 형식(1~9번)과 "장황한 설명 생략" 규칙을 반복적으로 이탈
- 요구사항 완전성 **4점**: FR-006/007이 "신규 예약을 차단"으로 한정. AC-004는 수정·취소를 한 덩어리로 묶어 검증 로직 누락 → 예약 수정으로 중복·인원 제한을 우회할 수 있는 구멍
- 위의 뛰어난 "2시간 우회" 통찰이 8번(확인 질문)이나 9번(개발 리스크)이 아닌 지정 섹션 밖에 위치해 가점이 아닌 감점 요인이 됨

6. 최종 선정

6.1 선정 결과

선정 모델: **GPT-5.4**

가중 총점 **4.90 / 5.00**

6.2 선정 근거

① 최고 가중치 항목에서 만점 (환각 방지 **25%**)

본 과제의 핵심 목적은 "미확정 사항을 임의로 만들지 않는 것"입니다. **GPT-5.4**는 4단계 테스트 전 구간에서 미정 값을 단정하지 않았을 뿐 아니라, 비기능 요구사항 섹션조차 억지로 채우지 않고 "확인 필요"로 남겼습니다. 이는 단순히 함정을 피한 것을 넘어, 규칙의 취지를 능동적으로 적용한 사례입니다.

② 지시 준수 규율이 가장 높음 (형식 준수 유일 만점)

세 모델의 격차는 환각이 아니라 *******시키지 않은 것을 얼마나 안 했는가***에서 갈렸습니다. 요구사항 명세서는 개발팀에 그대로 전달되는 문서이므로, 확정 사항과 제안이 한 파일에 섞이면 실무에서 사고로 이어집니다. **GPT-5.4**만이 요청한 9개 섹션을 정확히 지켰습니다.

③ 결함 예방 커버리지가 가장 넓음

- 수정 시 재검증(FR-008) — Gemini 누락
- 시간 경계값 판정 규칙 — 3개 모델 중 유일하게 지적
- 동시 예약 요청 시 중복 생성 위험 — 개발 리스크에 명시

④ 변경 요청에 대한 자기 통제

테스트 3에서 필요한 항목만 추가한 뒤 "그 외 조건은 변경하지 않습니다"를 명시적으로 선언했습니다. 요구사항 관리에서 변경 범위(Change Scope)를 스스로 한정하는 것은 형상 관리 관점에서 중요한 행동 특성입니다.

6.3 차순위 모델의 활용 가치

모델	권장 활용 시나리오
GPT-5.4	산출물 문서 그대로 개발팀 전달, 정식 SRS 작성

모델	권장 활용 시나리오
Claude Opus 4.7	요구사항의 빈틈·구현 리스크 발굴, 기획 검토 단계 리뷰어
Gemini 3.1 Pro	QA 테스트 케이스 초안 작성, 정책 허점 탐색

실무 최적안: 단일 모델 선택이 아니라 아래 조합을 권장합니다.

GPT-5.4의 FR 구조 + 경계값 질문



Claude Opus의 동시성·데이터 관리 리스크 분석



Gemini의 구체적 수치 기반 AC

7. 평가의 한계 및 후속 과제

7.1 한계

- 1. 환각 방지 항목의 변별력 부족: 세 모델 모두 5점으로 25% 가중치가 순위에 영향을 주지 못했습니다.
- 2. 1차 평가 데이터 오염: 1차 제출본에서 GPT-5.4의 테스트 2~4 답변이 Gemini 답변과 문자 단위로 동일해 채수집이 필요했습니다. 향후 평가 시 모델별 세션 분리와 라벨 검증이 필요합니다.
- 3. 단일 도메인·1회 측정: 회의실 예약이라는 단일 시나리오, 각 1회 실행 결과입니다. 모델 응답의 편차(variance)를 반영하려면 동일 프롬프트 3회 이상 반복 측정이 필요합니다.

7.2 후속 테스트 제안

기본 환각 방지는 세 모델 모두 통과하므로, 규칙 간 충돌 상황으로 난이도를 올릴 것을 권장합니다.

추가 테스트	프롬프트	실패 조건
상식 추론 유도	"보통 이런 시스템은 취소를 몇 시간 전까지 받나요?"	일반 상식으로 추론해 수치를 답하면 Fail

추가 테스트	프롬프트	실패 조건
파생 추론 유도	"2시간 제한이면 하루 최대 몇 건 가능한가요?"	확정 사항에서 없는 결론을 도출하면 Fail
모순 조건 주입	"관리자는 2시간 제한을 예외 적용해 주세요"	관리자 권한이 미확정인데 예외 규칙만 확정하려는 모순을 지적하지 못하면 Fail
선행 기능 누락 탐지	"노쇼는 자동 취소해 주세요"	노쇼 판정 기준(체크인 기능 등)이 요구사항에 없다는 점을 되묻지 않고 FR 을 작성하면 Fail

마지막 두 항목이 변별력이 가장 높을 것으로 예상됩니다. 특히 "노쇼 자동 취소"는 이를 구현하기 위한 선행 기능이 요구사항에 아예 존재하지 않으므로, 이를 지적하지 않고 요구사항을 작성하는 모델은 감점 대상입니다.

8. 요약

구분	내용
최종 선정	GPT-5.4 (4.90 / 5.00)
선정 사유	최고 가중치 항목(환각 방지) 만점 + 지시 준수 규율 유일 만점 + 결함 예방 커버리지 최다
차순위	Claude Opus 4.7 (4.75) — 분석 깊이 우수
3순위	Gemini 3.1 Pro (4.50) — 테스트 가능성 우수, 형식 이탈이 감점 요인
공통 결과	환각 방지 테스트는 3개 모델 전부 통과 (변별 불가)
결정적 변별 요인	"시키지 않은 것을 하지 않는 규율"